

• 体系结构与外围设备 •

云计算技术发展分析及其应用探讨

王佳隽, 吕智慧, 吴杰, 钟亦平

(复旦大学 计算机学院网络与信息安全研究所, 上海 200433)

摘要 : 基于云计算技术在国内外的相关研究, 分析了 Amazon 的 EC2, Google 的 App Engine, Microsoft 的 Azure 等云计算平台, 探讨了云计算技术的发展路线, 总结了云计算技术模型的一般框架, 以及云计算平台的三大固有特点: 平台用户不关心底层的实现; 非常灵活, 资源规模完全按照实际需求进行调节; 基于大规模的数据中心提供高性能、巨量的计算资源。介绍了云计算技术的一般技术框架以及未来的发展方向。

关键词 : 云计算; 虚拟化; 网络服务; 按使用付费; 规模可伸缩性

中图分类号 : TP393 **文献标识码** : A **文章编号** : 1000-7024 (2010) 20-4404-06

Cloud computing technology development analysis and applications discussion

WANG Jia-jun, LÜ Zhi-hui, WU Jie, ZHONG Yi-ping

(Network and Information Security Laboratory, School of Computer Science, Fudan University, Shanghai 200433, China)

Abstract : After analyzing existing cloud computing platforms such as Amazon's EC2, Google's App Engine and Microsoft's Azure, the general architecture and the technology development of cloud computing are presented based on relative researches at home and abroad. Then, three important characteristics of cloud computing are summarized: The details of the cloud platforms are invisible to the users of the platforms; Flexible, scalable resources on demand; Huge amounts of high-performance computing resources based on large-scale data centers. The general technology architecture of cloud computing as well as its future trends is introduced.

Key words : cloud computing; virtualization; web services; pay-as-you-go; scalability

0 引言

随着计算机以及网络技术的发展, 计算机性能的增长将面临瓶颈, 而网络技术的发展使得在全球范围内共享一些计算资源成为可能, 因此, 我们应利用大量的网络资源, 而不是个人手中的个别计算资源来提供高性能服务。网络计算自其提出以来, 一直致力于解决这一问题。但是网络面向应用, 为了调用网络的资源, 用户必须将其程序转换成分布式的, 而且程序员必须了解网络的内部结构。这些障碍导致了普通用户难以使用网络的资源。但是市场对于计算资源——无论是高性能计算, 还是面向 Web 2.0 的网络服务, 都有着强烈的需求。特别是 Web 2.0 技术的发展使得网络应用的范围大幅扩展, 网络不再是简单的信息发布或者信息传输的简单工具。SaaS (software as a service)、PaaS (platform as a service) 等概念的提出要求网络提供更加强大的服务。云计算正是在这种背景下被提出的。其实云计算并不是一个新概念。虽然其提出时间不长, 但是云计算的很多想法涉及网格计算、效用计算、集群技术、分布式系统技术等等比较成熟的技术。因此从另一个角度分析, 云计算也可以看作是对这些技术的升级、集成。随着

相关技术的发展, 云计算的商业应用已经成为现实。如 Amazon 的 EC2, 微软的 Azure 等云计算平台都已经或者将要出现在市场之上。云计算为我们提供了一种新的计算模型, 同时也意味着一种新的 IT 商业模式。

本文基于现有的国内外相关研究, 探讨云计算技术本身的主要特点, 以及基于云计算技术的新型应用, 以期读者能通过阅读此文, 对云计算技术有较为全面的了解。本文首先介绍了云计算的概念; 从商业模式的角度分析了云计算中的相关角色; 通过比较现有的几种云计算应用, 分析总结了云计算基础技术架构。最后文章讨论了云计算发展遇到的障碍, 并且对未来的趋势做了展望。

1 云计算的概念分析

1.1 云计算发展背景

云计算的突然兴起和网络应用的转型密不可分。随着 Web 2.0 的概念从理论到实践, 从少量实验性网站到今天的校内网等吸引大量用户的应用, 网络正从一种“紧密联系, 高维护成本, 高承诺义务”的时代转换为“松散耦合, 低维护成本, 低承诺义务”的商业模式。以网站为例, 对网络应用提供商来

收稿日期: 2009-11-12; 修订日期: 2010-01-12。

作者简介: 王佳隽 (1985—), 男, 上海人, 硕士, 研究方向为系统管理、SOA、Web 服务、云计算; 吕智慧 (1975—), 男, 博士研究生, 研究方向为系统管理、P2P 等; 吴杰 (1973—), 男, 副教授, 研究方向为系统管理、P2P 等; 钟亦平 (1953—), 女, 教授, 博士生导师, 主要研究方向为新一代网络技术、网络的一致性测试和安全测评认证技术、信息安全技术等。E-mail: 082024064@fudan.edu.cn

说:维护一个大型的可以赚钱的网站往往意味着维护一个从硬件维护人员到市场分析、服务设计人员的大团队,并且公司必须对硬件、软件问题完全负责。而最终赚取利益的网络服务可能只是这个巨大系统金字塔的顶上的小部分。这种不平衡的特征极大的阻碍了网站的进一步发展。对于此类利用网络提供服务的组织机构来说,传统的计算模型存在的困难体现在如下4个方面:

(1)中小型组织缺乏搭建大型底层基础设施所需的启动资金,而即使是大型组织,也很难短期内筹集到足够的资金。市场上机会稍纵即逝,快速起步的能力至关重要。

(2)从底层进行开发的成本高。即使最终需要的仅仅是最顶层的少量服务,服务提供者也必须从硬件开始搭建,其开发时间和人员投入成本高。

(3)当服务成型上线,服务提供商还需负责维护,而无法将精力集中于新业务的开发。

(4)缺少规模可伸缩的服务支持平台,不能配合需求的变化。当服务的业务需求发生较大变化,或者仅仅是服务的规模提升或者缩小时,传统的计算模型需要进行较大的修改。

而通过云计算平台这种灵活高可靠的平台,用户可以基于平台提供的现有服务迅速搭建系统,并且将维护基础设施的任务移交给专业机构(云提供商),这样他们可以集中精力完成业务相关的操作。同时,云平台的规模可伸缩性可以满足服务业务变化的需求,减低服务的成本。

1.2 云计算的定义

Andy Isherwood 在 2008 年 12 月说:很多人转而研究云计算,但是我从没有听说两个人说得是一回事的。Larry Ellison 在华尔街日报提到:关于云计算有一个有趣的现象是,我们往往根据我们做出的东西而去重新定义云计算。关于云计算有很多定义,而现有的云计算平台实现也五花八门。Ian Foster 等人的研究^[1-3]对与现有的云计算定义进行了总结和分析,以下摘录其中比较有代表性的定义:

(1)用户可以以分钟甚至秒来规划用户的基础设施使用,而不是按一天或者一周,这样避免了资源的空闲(浪费)或者资源的过载;

(2)一朵云是一种并行分布式系统,它由一系列联网、虚拟化的计算机提供服务层的同步、统一计算资源;

(3)云计算是一个涉及了多个方面考虑的概念,诸如发布,负载平衡,事务模型,架构模型等。它是软件的下一个逻辑阶段。对我来说关于云计算的最简单定义是:“因特网集成软件…”。

这些观点有的强调服务资源的提供,有的强调基础设施的虚拟化,有的强调网络服务的概念。它们实际上是对于云计算这一概念的不同侧面的解读。

和云计算相关的概念有:网络计算、集群技术、超级计算机,它们是几个互相区别又有其内在联系的概念。云计算以面向服务的方式提供给用户计算资源,并且其平台可能比网络、传统集群拥有更大的规模,从而云计算平台提供的计算性能很可能高于超级计算机。而另一方面网络、超级计算、集群等技术提供的服务往往针对特定的应用,其规模、灵活性不及云计算技术。

综合相关的研究,云计算可以被定义如下:云计算就是将

应用以服务的方式通过因特网进行发布,以及实现这些服务所涉及的硬件以及系统软件。其中云这个词特指硬件以及系统软件,而服务则是云用以服务用户,赚取商业利益的关键。

1.3 云计算平台的特点

如图1所示,云平台屏蔽了底层的软硬件实现细节,并且提供连接服务的标准接口,使得所有连接 Internet 的用户都可以方便的接入云平台使用计算资源。目前已实现的云计算平台都符合云计算的基本技术框架,但是各个公司或者组织的侧重点又有所不同。大致可以分为3类:基于虚拟化技术提供底层基础资源服务;統合云计算平台内部的资源,提供功能特化的上层服务资源;統合平台内部的基础资源,提供基于网络服务的计算平台。




图1 云计算平台基本技术框架

无论基于何种目标,云计算平台都应具备以下3项特点:

(1)用户不必关心云平台底层的实现。用户使用平台,或使用云平台发布第三方应用的开发者(服务提供商,或者云平台用户)都不必理解云内部的细节,他们只需要调用平台提供的接口就可以在云平台中完成自己的工作;

(2)云平台非常灵活,其规模完全可以按照实际需求进行调节。利用虚拟化技术,云平台提供商可以实现按需提供服务,这一方面降低了云的成本,另一方面保证了用户的需求得到满足;

(3)云平台基于大规模的数据中心或者网格,因此云平台可以提供高性能的计算服务。并且对于云平台用户,云的资源几乎是无限的。

2 云计算中的角色分析

Berkeley 在云计算方面进行的调研^[5]阐述了当前云计算领域的理论观点,在云计算环境中用户可以被分为3类。这些用户层次及其供求关系如图2所示。

(1)底层是云的提供商,它提供了云的基础设施以及基本服务,这个角色一般都由大公司担任,因为云计算的高性能以及服务保障需要大量的设备、保障措施以及人力来实现,这不是一般的小公司或者团体可以实现的。Amazon^[6]属于目前较为成功的云提供商,除了提供 EC2 这类的基础设施级别的服务,它同时也提供云平台数据库服务、存储服务等等可以为一些最终用户直接使用的服务类别。但是由于云提供商着眼于云平台本身,只能提供一般化的解决方案,难以提供针对用户需求的特定服务,这就需要服务提供商或者用户自身利用平台进一步开发自定义的服务。

(2)通过底层的基础设施通过效用计算模型提供的云基础服务,比如存储服务、CPU 计算资源等等资源。中间层用户中间层包含了两种角色,服务提供者或者云的直接使用者。他们可能是云的终端用户,也可能是基于云这一平台进行二次




图2 云计算的用户层次及其供求关系

开发进而发布自己公司云计算应用以此谋取商业利益的软件供应商。中间层角色一方面租用云平台的资源，一方面对云的基础服务进行包装、升级，依靠最终用户来赚取利益。就目前运营的云计算平台实现来看，大多不同程度的提供了对第三方应用发布的支持。未来云计算世界中最为活跃的很可能就是这一层。就像现在淘宝提供了网上交易的平台，而众多网络卖家在其平台上开店一样，未来的云平台上也会出现众多的服务提供商提供大量的按使用计费的服务。服务提供商的优势在于可以针对不同用户的特定需求进行特定服务的开发、整合、发布，这使得服务提供商的服务非常适用于最终用户。而另一方面，由于利用了云平台的底层服务支持，云平台服务提供商的成本将大大低于传统IT服务提供商。

(3)云的最上层，最终用户使用云服务提供商或者直接使用云提供商提供的基础服务(如基础存储服务)来完成自己的工作，并且支付相应的费用。

3 云计算总体技术架构分析

目前研究中的云计算平台很多，通过分析总结这些现有的平台，可以了解云计算的总体技术架构。

3.1 现有典型云计算模式的应用分析与对比

3.1.1 微软 Azure

微软的云计算平台全称 Azure Service Platform。通过总结微软公司公布的资料^[7]，对 Azure 的整体技术结构可见一斑。微软的 Azure 服务平台是一整套云计算技术，基于分布于全球范围的分布式大规模数据中心向应用开发者提供一系列特定的服务。如图3所示，Azure 服务平台既可被在云端上运行的应用调用，也可被在本地系统运行的应用调用。在网络情况不稳定，或者数据保密性要求较高时，计算会在本地进行，而对于特定的云计算应用，则通过因特网连接 Azure 平台进行计算服务。这种模式对于云计算的逐步普及是很有意义的，通过渐进的用户使用习惯、软件不断升级换代，最终实现绝大多数应用被搬入云中。Azure 服务平台的组件能被在本地运行的各种系统中的软件调用。其中包括 Windows，移动设备和其




图3 Azure 服务平台支持在云和本地系统运行的应用

它平台。这些组件包括：

(1)最基本的 Windows Azure 提供一个基于 Windows 环境可运行应用和将数据存储在微软数据中心的服务器上的平台。

(2)Microsoft .NET Services 向基于云和本地的应用提供分布式的基础设施服务。

(3)Microsoft SQL Services 向云提供基于 SQL Server 的数据服务。

(4)Live Services 通过 Live Framework，提供来自微软 Live 应用及其它应用的数据访问。

3.1.2 Google

Google 的云计算技术是针对 Google 特定的网络应用程序而定制的。Google 的内部网络数据规模巨大，为了处理这些数据，Google 提出了一整套基于分布式并行集群方式的基础架构，利用软件的能力来处理集群中经常发生的节点失效问题。Google 使用的基础架构包括 4 个相互独立又紧密结合在一起的系统。包括 Google 建立在集群之上的文件系统 Google File System，针对 Google 应用程序的特点提出的 Map/Reduce 编程模式，分布式的锁机制 Chubby 以及 Google 开发的模型简化的大规模分布式数据库 BigTable。基于这一系列的组件，Google 将其基础架构整合成为统一的云计算平台，主要提供平台 API 服务以及一系列的网络应用服务。

3.1.3 Amazon EC2

相比微软和 Google 的云计算平台，Amazon 的 EC2(弹性计算云)在商业化的路上要走的远得多。用户可以通过简单的网络服务接口使用或者配置资源，将其申请的资源作为网络虚拟机完全的控制。这种申请资源并且启动新服务实例的时间间隔将达到分钟级别，这意味着 EC2 可以迅速满足用户的请求，并且以细粒度分析用户的使用情况。无论是扩展规模还是减少规模，系统都可以满足。

从技术架构上来说，EC2 生成提供了一个真正完全虚拟化的计算环境，只要用户申请资源，EC2 就可以提供可以符合多种系统需求的计算环境以及响应的资源。但其主要技术层面在虚拟化层面，其提供的服务是利用虚拟化技术提供的基础实施服务资源，如存储、虚拟机等。

特点包括如下 3 点：

(1)弹性。所谓弹性计算云，其首要的优势当然是可以提供弹性的计算能力。所谓弹性就是指在用户的需求增加或者减少时，可以迅速的满足用户在计算规模上要求的变化。

(2)灵活。EC2 提供的平台是底层资源，而用户在其上运行何种操作系统、何种应用的都是很灵活的。通过配置内存、CPU

以及实例的存储用户可以为各种环境配置出合适的平台。

(3)可靠。EC2 对于运行的实例都提供可以在出问题是快速替换的备用实例。实例运行的环境非常可靠, EC2 的服务级别协议对于所有的地区都有 99.95% 的保证。

3.1.4 3 种模式的比较

Berkeley 的研究^[5]总结了 3 种平台的技术模型差异, 表 1 基于 Berkeley 的研究有所补充。无论何种平台, 它们提供的服务、收费标准的区分一般可以分为 3 类: 计算资源(CPU 等)、存储、网络传输。也就是说不同平台之间对于这 3 类服务会有不同的技术模型。

除了表 1 在资源模型方面的比较, 从用户使用平台的角度来看, Amazon 更偏向底层基础平台、资源的提供, Google 提供上层的编程 API, 底层对编程人员不可见。而微软的 Azure 虽然也基于大量自动的分配以及程序员 API, 但是程序员也可以通过修改组件描述来限定资源的提供, 故 Azure 介于 Amazon 和 Google 的模式之间。

一方面, 对于 Amazon 这样在模型中为用户提供低级别语言支持的平台, 那么用户确实可以通过它来完成各式各样的计算任务, 但是使用实例时, 用户必须关心系统细节, 代码将会冗长而复杂。另一方面, 对于提供高级别语言支持的框架, 那么用户就必须将自己的应用嵌入现有框架内, 比如对于 Google 的交互式 API, 应用就必须符合请求/应答的模式。但从编码的角度, 程序员则可以省力不少。

3.2 云计算总体技术架构

上述的 3 种云计算平台侧重点各异, 但按照平台的相关技术以及研究内容区分, 其技术框架可以被划分为几个层次。我们将云计算的基本技术框架总结为 4 层: 底层基础设施层、虚拟化层、服务资源层和服务提供层, 如图 4 所示。

(1)第 1 层, 底层基础设施层。在这一层面, 地理上分布的物理机器通过网格、集群技术的服务封装^[13]组成大规模的具有 SLA 保证的数据中心。

(2)第 2 层, 虚拟化层。基于基础设施的数据中心或者大规模分布式系统, 利用虚拟化技术建立虚拟层, 以此提供逻辑独立的虚拟机。这个机制提供了云计算架构动态分配、管理计算资源的能力。目前有大量的研究集中于这个领域: 如何高效的进行物理资源和逻辑虚拟机之间的映射; 如何对大量的虚拟资源进行有效的管理; 如何针对不同的应用映射相适




图 4 云计算总体技术架构

应的虚拟资源。Pradeep Padala 等的研究^[14]针对基础设施虚拟化技术难以满足服务级别要求的问题, 提出了一种自动化的动态负载资源管理系统。SnowFlock 系统^[15]以及 Hirofuchi 等的研究^[16]则针对大量资源管理环境中, 有效的进行虚拟机克隆提供了思路。虚拟化技术使得原本静态的物理资源得以动态使用, 统一了平台的基础设施接口, 使得云计算平台可以提供对用户透明的计算资源。

为了支持上层的云服务, 虚拟机制必须能满足以下条件:

1) 计算资源对用户请求必须是一种接近无限可用的状态, 那样用户才可以不考虑平台的细节而自由的使用需要的资源服务, 当应用需要扩展时系统也不会因为资源短缺而报错;

2) 消除用户预先预定资源的要求, 也就是说可以动态的调节资源的规模;

3) 基于短时间计算费用的能力, 比如说按分钟计算 CPU 使用或者存储使用等。这一点也包括了短期释放资源然后能立即重复利用的管理能力。

(3)第 3 层, 服务资源层。直接基于虚拟资源的平台的资源管理, 提供具有 SLA 保证的云计算服务资源。虚拟化层面的资源距离提供具有 SLA 保证的云计算服务尚有一定距离, 在云计算平台内, 还必须对虚拟化资源进行统一的管理, 基于服务功能调用特定的资源, 平台还必须解决包括环境配置、资源的优化调整等等的问题。

通过云计算平台的支持, 可以向用户提供 SaaS、PaaS、IaaS

表 1 3 种云计算平台的资源模型比较

	Amazon Web Services	Microsoft Azure	Google AppEngine
虚拟机计算模型	提供易于监控的弹性计算资源。开发者可以利用实例进行任何形式的计算任务。但是开发者自己负担构造实例的任务, 或者让第三方提供支持。	基于微软的 Microsoft Common Language (CLR) 虚拟机技术。提供自动负载平衡。计算模型是受监控管理的, 并非可以完全执行所有命令 (受限于 CLR), 而负载平衡等基础功能则无需开发者关心。	预先定义了应用的框架与架构, 为编程人员提供了基于 Python 的处理服务。所有的持续状态存储都被放在 MegaStore 之中。完全自动的计算规模、存储资源规模变动。
存储模型	根据用户选择的服务, 平台使用无自动调节的存储模型 (EBS) 或者提供调整的存储模型 (SimpleDB, S3)。不同模型提供不同的保障。	(1) SQL 数据服务 (局限于 SQL 的服务) (2) Azure 存储服务。两者都是微软提供的存储服务, 用户难以使用自定义的存储服务。这意味着接口都必须使用微软定义的。	(1) BigTable (分布式大规模数据库管理系统) (2) MegaStore (基于 BigTable 的面向用户应用的可调节规模存储模型)基本上 Google 的存储模型是专为 Google 的网络应用设计, 不支持其它的应用。
网络模型	基于 IP 层的公开标准, 内部细节被隐藏。由安全组提供对于各个节点通信的限制。	基于编程者对于应用组件 (ROLE) 的描述来自动分派。	固定的基于 3 层网络应用架构的拓扑。其规模变化对于编程者不可见。

等服务。Infrastructure as a Service(IaaS)将基础设备作为提供的资源,比如存储或者计算处理能力。它同时也是平台提供高层服务的基础。Platform as a Service(PaaS)是利用云平台的能力提供的额外抽象层。它提供的资源就是软件平台本身,而非虚拟化的基础设备。Google 的 Apps Engine 就是这种平台的最好例子。而 Software as a Service(SaaS)将原先只能安装在本地的软件转移到云端,会大大方便用户的使用,于此同时这种云端的软件又会使用不同于传统软件的购买方式。而云平台的存在也使得软件用户之间交换数据更加方便,很可能产生新型的软件交互模式。

(4)第4层,服务提供层。除了保证平台功能的管理技术,云计算平台还需要业务相关的管理措施,基于服务资源并且向用户提供服务的发布、管理。包括用户认证、请求管理、分派等功能,其中最重要的是平台的计费管理。按照使用付费是云计算平台业务服务管理核心内容。为了支持按使用付费,云计算平台还需要同时满足:按照使用分派资源,计算使用量等相关的技术。针对内存、磁盘空间等等资源的分派和使用量统计已有可用的成熟方法,但是系统 I/O 以及 CPU 等资源的精确计量仍有待进一步研究。在实际应用中,用户请求的波动是很明显的,白天和晚上的用户请求就完全不同,由于资源使用率往往较低,无论对于服务提供方或是服务使用者,都造成巨大的浪费。因此云提供商能否减少资源浪费,又能保证用户请求得到满足,就需要完善的管理手段。

关于云计算服务提供以及服务资源本身的研究、实践尚处于发展阶段,多数研究成果是基于传统应用的改进或者仅能解决云计算技术的一小部分问题。MacroComponents^[17]的相关研究提出了一种在虚拟化分布式云计算环境下利用提高软件分块独立性,进而提高平台运行效能的手段。关于云平台能提供的服务范围非常广, Gianni Fenu 等的研究^[18]以及 Matsunaga 等的 CloudBLAST 系统^[19]都提出了使用云计算高效的特点提供对于计算需求较高的服务, Ricardo Vilaça^[20]、Broberg^[21]等的设计则针对云计算平台资源数量大的特点,提出了大规模存储、分发内容的方案,另外 Dörnemann 等的研究^[22]以及 Christina Hoffa 等的研究^[23]提出了对平台服务资源进行组合管理,提供工作流支持的设计。可见云计算可以利用自身优势提供传统计算模型所不能或者较难提供的高效、大规模、高灵活的服务。

4 结束语

云计算的时代已经逐步到来。告别有限的计算资源,告别耗时耗力的维护工作,市场需要云计算,而 IT 业的进一步发展也确实需要云计算。

但是不可否认,运营级的应用和云计算的真正接轨还是有很长的路要走。有学者指出:云计算的基础设施技术还需要 7 年时间来成熟。2009 年的云计算市场还是处在早期市场,多数企业仍处于观望阶段。根据 Berkeley 大学的相关研究^[5],云计算技术距离完全实现其愿景尚存在的 10 大障碍:①服务的可用性的保证;②数据锁定,平台之间数据的转移;③数据保密性和可审计性;④数据传输瓶颈;⑤性能不可预测性;⑥高效、细粒度的弹性存储;⑦大型分布式系统中易于存在 bug;⑧高效

准确的计量;⑨服务供应商以及平台其它用户的声誉命运共享;⑩新的计算资源、服务商业模型带来的软件许可证问题。

虽然存在诸多问题,但是云计算无论在研究领域还是在 IT 市场上的雏形正在逐步形成,它为供应商提供了全新的机遇并催生了传统 IT 产品的转变。在未来的几年里云计算还将继续发展,其应用领域也会进一步扩展,届时针对云计算平台以及云计算服务的研究和开发必将成为计算机学界的一大热点。

参考文献:

- [1] Ian Foster,Zhao Yong,Ioan Raicu,et al.Cloud computing and grid computing 360-degree compared[C].Grid Computing Environments Workshop,2008:1-10.
- [2] Mladen A Vouk. Cloud computing-issues, research and implementations[J].Journal of Computing and Information Technology,2008(4):235-246.
- [3] Luis M Vaquero,Luis Rodero-Merino,Juan Caceres,et al.A break in the clouds:Towards a cloud definition[C].ACM SIGCOMM Computer Communication Review,2008.
- [4] Rajkumar Buyya,Chee Shin Yeo,Srikumar Venugopal.Market-oriented cloud computing:Vision,hype,and reality for delivering IT services as computing utilities [C]. HPCC, IEEE CS Press, 2008.
- [5] Armbrust M,Fox A,Griffith R,et al.Above the clouds:A berkeley view of cloud computing[EB/OL]. <http://www.eecs.berkeley.edu/Pubs/TechRpts/2009/EECS-2009-28.pdf>.
- [6] Amazon elastic compute cloud(amazon EC2)[EB/OL]. <http://aws.amazon.com/ec2,2009>.
- [7] MicroSoft. Cloud computing platform: Azure service platform overview[R].INSIGHT(MicroSoft),2008.
- [8] Hadoop[EB/OL]. <http://hadoop.apache.org,2009>.
- [9] Hadoop 中文资料 [EB/OL]. <http://www.cloudcomputing-china.cn,2009>.
- [10] Siegele L.Let it rise:A special report on corporate IT[C].Economist,2008.
- [11] Giacomo V Mc Evoy,Bruno Schulze.Using clouds to address grid limitations[C].Proceedings of the 6th International Workshop on Middleware for Grid Computing.New York,NY,USA: ACM,2008:1-6.
- [12] Wang Lizhe,Tao Jie,Marcel Kunze,et al.Scientific cloud computing:Early definition and experience[C].10th IEEE International Conference on High Performance Computing and Communications,2008:825-830.
- [13] Francesco Maria Aymerich,Gianni Fenu,Simone Surcis.An approach to a cloud computing network[C].First International Conference on the Applications of Digital Information and Web Technologies,2008:113-118.
- [14] Pradeep Padala,Hou Kai-Yuan,Kang G Shin,et al.Automated control of multiple virtualized resources[C].EuroSys,2009.

- [15] Horacio Andres Lagar-Cavilla, Joseph Andrew Whitney, Adin Matthew Scannell, et al. SnowFlock: Rapid virtual machine cloning for cloud computing[C]. Nuremberg, Germany: Proceedings of the Fourth ACM European Conference on Computer Systems, 2009.
- [16] Hirofuchi T, Nakada H, Ogawa H, et al. A live storage migration mechanism over wan for relocatable virtual machine services on clouds[C]. Proceedings of the International Workshop on Cloud Computing, 2009.
- [17] Chris Matthews, Yvonne Coady. Virtualized recomposition: Cloudy or clear[C]. Proc CLOUD, 2009.
- [18] Gianni Fenu, Simone Surcis. A cloud computing based real time financial system [C]. Eighth International Conference on Networks, 2009.
- [19] Matsunaga A, Tsugawa M, Fortes J. CloudBLAST: Combining mapreduce and virtualization on distributed resources for bioinformatics applications[C]. Submitted to eScience, 2008.
- [20] Ricardo Vilaca, Rui Oliveira. Clouder: A flexible large scale decentralized object store [C]. Nuremberg, Germany: WDDM, 2009.
- [21] Broberg J, Tari Z. MetaCDN, Harnessing storage clouds for high performance content delivery [C]. Sydney, Australia: Proc Sixth Int Conference on Service-Oriented Computing, 2008.
- [22] Dornemann T, Juhnke E, Freisleben B. On-demand resource provisioning for BPEL workflows using Amazon's elastic compute cloud [C]. Proc of the 9th IEEE/ACM Int Symposium on Cluster Computing and the Grid, 2009: 140-147.
- [23] Christina Hoffa, Gaurang Mehta, Timothy Freeman, et al. On the use of cloud computing for scientific workflows [C]. Proc of the 2008 Fourth IEEE International Conference on eScience, 2008: 640-645.

(上接第 4356 页)




图4 PageRank 并行算法与串行算法完成时间




图5 PageRank 并行算法的加速比

从图4可以看出,随着网页数据集数量的增加,串行算法的完成时间增长很快,而并行算法的完成时间却增长缓慢,说明基于 MapReduce 的 PageRank 改进算法更适合处理网页数据集数量较大的情况。

从图5可以看出,在机群节点数固定情况下,数量大的网页数据集比数量小的网页数据集有更高的加速比,这主要因为每个机群计算节点分配到的数据量更多,能够进行更大粒度的并行计算。

5 结束语

针对 Nutch 没有实现 PageRank 计算的缺憾,本文对经典 PageRank 算法进行改进,在 Nutch 机群系统中设计并实现了基于 MapReduce 的 PageRank 并行算法。实验表明:处理数据量越大,机群节点越多,计算 PageRank 的效率越高;另外,该并行算法具有较好的可扩展性。下一步研究工作是在 Nutch 的网页综合排序评分算法中融入 PageRank 计算因子,并考虑网页更新时间和用户点击度等因素,进一步改进 Nutch 的网页排序效果,提高 Nutch 的用户使用满意度。

参考文献:

- [1] Hadoop. What is Hadoop [EB/OL]. <http://hadoop.apache.org>, 2009-07-25.
- [2] Tyrell Perera. Nutch-the Java search engine [EB/OL]. <http://wiki.apache.org/nutch>, 2009-08-25.
- [3] Dean J, Ghemawat S. MapReduce: Simplified data processing on large clusters[R]. San Francisco: Google, 2004.
- [4] Ralf Lammel. Google's MapReduce programming model-revisited[J]. Science of Computer Programming, 2008, 70(1): 168-172.
- [5] HDFS. The hadoop distributed file system: Architecture and design [EB/OL]. http://hadoop.apache.org/common/docs/hdfs_design.html, 2009-08-26.
- [6] Will Pugh. How to setup Nutch over a cluster of machines [EB/OL]. <http://wiki.apache.org/nutch>, 2009-08-28.
- [7] 黄德才, 戚华春. PageRank 算法研究[J]. 计算机工程, 2006, 32(4): 145-146.
- [8] 王冬, 雷景生, 李壮. 基于 PageRank 的页面排序改进算法[J]. 计算机工程与设计, 2008, 29(22): 5921-5923.
- [9] 王学松. Lucene+Nutch 搜索引擎开发[M]. 北京: 人民邮电出版社, 2008: 368-375.